TECHNICAL DESIGN / PROOF OF CONCEPT

社内RAGシステム PoC 技術詳細設計書

Stella Knowledge ┆ 蒼星デジタルソリューションズ株式会社（架空企業）

本書の位置づけ

要件定義書 SDS-RAG-REQ-001 v1.0（2026年11月9日）に基づく、実装演習用のPoC設計ベースライン。架空データのみを扱い、本番機能の全受入を意味しない。

管理項目	内容
文書ID	SDS-RAG-POC-DES-001
版・作成日	v1.0 / 2026年11月10日
対象	PoC開発者・レビュー担当者
先行文書	要件定義書 v1.0、企業マスタ、文書メタデータ
設計状態	実装用提案（技術選定・評価閾値は検証で更新）

基本方針：小さく実装し、測定結果から本番設計を決める。

1. 目的・スコープ・位置づけ

目的は、架空社内文書に対して「取り込み → 権限付き検索 →
根拠付き回答」が成立するかを測定し、技術的な不確実性・セキュリティ上の懸念・本番移行条件を整理すること。

区分	PoCでの取り扱い
対象文書	登録：100件すべて。初期回答の対象はHR30 / IT25 / SC10 の65件。SA20 / MG15 は権限と段階公開の試験用。
利用者	模擬テストユーザー。要件上のPoC対象は3部署16名であり、CLIで代表的な権限パターンを再現する。
機能	6形式の文書抽出、版管理、ACL付き検索、日本語回答と出典、評価ログ。
対象外	RidgeID実接続、SSO、Web UI、承認ワークフロー、20並列負荷保証、365日ログ運用、可用性保証。
本番への出力	採用候補技術、性能・品質データ、リスク一覧、Go/Conditional Go/No-Go判断。

1.1 要件定義との差分管理

要件定義上の生成モデル「SoseiLM-8B」は架空コンポーネント。PoCでは利用可能なQwen2.5 7B Instructに置換し、差分を明示する。本番想定のHybrid Search・任意の再ランキングはPoCでは比較対象（初期ベースラインはDenseのみ）。

本番の最終受入は開発用100問＋独立した受入用100問とAT-01〜AT-10を前提とする。PoCの初期8問と追加30〜50問は技術選定の一次評価であり、本番受入試験の代替ではない。

1.2 成功条件

・全100件を管理対象として突合し、登録不能ファイル・抽出欠損を個別に把握できる。

・許可済み文書のみから回答・引用し、許可外文書のタイトルや存在を明かさない。

・検索精度、回答品質、版選択、攻撃耐性、処理時間を再現可能な手順で測定できる。

・未解決課題・本番への改修候補を、証拠と優先度付きで残せる。

2. 採用技術と無償実行条件

領域	採用候補	補足
実行	Python 3.11 / CLI	venv と依存バージョン固定
検索DB	ChromaDB（ローカル）	Cosine・永続化
Embedding	intfloat/multilingual-e5-small	query: / passage: 接頭辞・正規化
生成	Ollama + Qwen2.5 7B Instruct	ローカル推論、temperature=0
抽出	PyMuPDF、python-docx、openpyxl、bs4、csv	PDF / DOCX / XLSX / MD / HTML / CSV
テスト	pytest / JSONL / YAML	ローカルで実施

追加のAPI・クラウド利用料は0円を想定。ただし電気代、開発工数、ストレージ、初回ダウンロード通信は別途。PyMuPDFはAGPL/商用ライセンス条件を本番採用前に確認する。

3. システム処理設計

3.1 オフライン文書登録（Ingest）

metadata.jsonl ＋ data/100文書
↓ ファイルパス照合・形式/容量/アクセス権メタデータ検証
↓ PDF/DOCX/XLSX/MD/HTML/CSVをテキスト・位置情報へ抽出
↓ 見出し・段落優先のチャンク化（基準：500文字/重複100文字）
↓ passage: 接頭辞 → E5 Embedding → ChromaDB upsert
↓ 文書登録結果・エラー一覧・索引設定を保存

3.2 オンライン質問応答（Ask）

ユーザーID ＋ 質問 ＋ optional 基準日
↓ ローカルのユーザー定義からグループを確定（未登録は拒否）
↓ 全体公開スコープ ＋ 文書状態/日時 ＋ ACLで候補集合を確定
↓ query: 質問 → E5 Embedding
↓ ChromaDBでACL適用済み候補からTop 5を取得
↓ チャンク本文のみを参照資料としてLLMへ渡す
↓ 回答と出典を検証（権限・引用ID・根拠整合）
↓ 結果・時間・エラーをJSONLへ記録

絶対条件：検索前ACL

「検索してから見せない」ではなく、候補文書集合の作成時点で認可を適用する。LLMへ禁止文書を渡さない。ログ・出典・例外メッセージにも機密データを出さない。

3.3 コンポーネント境界

モジュール	責務	主な入出力
loader.py	フォーマット別抽出	ファイル → 本文・位置
chunker.py	意味の切れ目を優先して分割	本文 → チャンク列
embeddings.py	E5エンコード	文字列 → ベクトル
indexer.py	索引作成・更新・削除	チャンク → DB
acl.py	許可集合と日時条件を確定	ユーザー・条件 → Filter
retriever.py	安全な候補検索	質問・Filter → Top K
generator.py	回答生成・引用ID検証	根拠文 → 回答
pipeline.py	フロー・例外・計測	問合せ → 構造化結果

4. データ仕様・前処理

4.1 入力コーパス

部門	件数	ファイル形式
人事総務 / HR	30	全6形式を混在利用
情報システム / IT	25	同上
営業 / SA	20	権限・段階公開試験
経営企画 / MG	15	権限・段階公開試験
情報セキュリティ / SC	10	初期回答対象
合計	100	PDF38 / DOCX24 / XLSX17 / MD16 / HTML3 / CSV2

原本に加えて data/README.md
があるため、拡張子単純集計でMDを17件と誤算しない。登録対象はmetadata.jsonlの100レコードに限定する。

4.2 メタデータと検証規則

metadata.jsonl の実フィールド：document_id、company、department、category、file_name、format、owner、classification、allowed_groups、status、effective_from、updated_at、description、relative_path、size_bytes。

・document_idの重複を禁止し、相対パスの外側への参照（../ 等）を拒否。許可された拡張子だけを処理。

・allowed_groups未設定・異常、抽出本文0文字、形式不一致、ファイル欠損はインデックスから除外（Fail Closed）。

・version と effective_to は既存メタデータにないため、PoC補助ファイル versions.yaml に明示して検証する。

・ZIP内に文字化けした日本語エントリ名が存在する。document_idをキーに原本突合し、安全な作業コピー上で修復する。原本ZIPは保持する。

4.3 抽出・チャンク・引用位置

形式	抽出・位置情報の扱い
PDF	PyMuPDFで本文・ページ番号。文字抽出に失敗したページは明示的にエラー（OCRは初期対象外）。
DOCX	段落・表の行列関係と見出し。段落またはテーブルの位置を保持。
XLSX/CSV	シート・ヘッダー・行番号・列値を組で表現。式と表示値の差分を確認。
MD/HTML	見出し階層と本文。HTMLはscript/styleを除去し実行しない。

チャンク：初期500文字、100文字重複。表は行単位を優先し、各チャンクにdocument_id・chunk_id・page/section/sheet/row・原本位置・ACL属性を引き継ぐ。チャンク境界とモデルが変われば索引を再生成する。

5. 認可・公開範囲・版制御

5.1 ローカルACLモデル

テストユーザーはfixtures/users.jsonに固定。CLI指定はユーザーIDのみで、グループを質問パラメータから受け取らない。認証自体は模擬であり、本人性の保証は本番SSOに委ねる。

許可判定は user.groups ∩ document.allowed_groups ≠ ∅。ただし「全社員」は実際の登録ユーザーにのみ付与し、未登録・停止ユーザーは拒否。機密区分（社内・機密・極秘）から権限を推論しない。

5.2 検索条件の結合

```
authorized = valid_user AND group_intersection
published = in_initial_65_documents OR explicit_test_scope
temporal = active_at(reference_date) OR explicit_history_query
eligible = authorized AND published AND temporal AND valid_metadata
```

ChromaDBの検索用メタデータはスカラー属性に正規化する。allowed_groupsの配列は、group_XXX=true等に展開して条件を組み立てる。グループ間OR、公開条件と日時条件のANDを誤らないこと。

5.3 旧版・現行版

既存の状態は有効98件、廃止2件。通常質問では現行版のみ。過去日付が指定された場合、当該時点に有効な版を選ぶ。適用終了日は versions.yaml に登録し、開始日時＜終了日時を検証する。期間の重複・欠損は保留扱いにする。

5.4 レスポンス・ログの最小開示

・権限外の資料は文書名、存在、件数、本文、引用IDを返さない。検索0件と権限外を利用者には同じ系統の案内にする。

・検索結果のdocument_idから、応答前に再度ACL検証。引用可能なのは実際に取得したチャンクのIDのみ。

・監査ログは質問ID、ユーザーの擬似ID、出典ID、アクセス判定、処理時間、回答状態を記録。原文全文をデフォルト保存しない。

6. 検索・生成パラメータ

項目	初期設定	比較候補・注意
検索	Dense / Cosine / Top K=5	Top K=3・10、Hybrid Searchは改善候補
Embedding	multilingual-e5-small	query:/passage:、ベクトル正規化
チャンク	500 / overlap 100文字	300・800文字を比較
LLM	qwen2.5:7b-instruct	Ollamaの配布タグ・量子化を固定
生成	temperature=0 / max 512 tokens	再現性のため版・seed等も記録
出力	日本語回答 + 出典 + 対象日	根拠不足・矛盾は回答保留

7. ディレクトリ・設定・CLI

7.1 既存構成の維持

```
RAG_Dev_Simulation/
    data/                                   #  既存100文書・metadata・評価QA
    docs/                                   #  既存企業概要・要件定義
    src/                                    #  本実装用（現時点では変更しない）
    poc/
        main.py                             #  ingest  /  ask  /  evaluate
        config.yaml
        requirements.txt
        rag/
            loader.py,  chunker.py,  embeddings.py,  indexer.py
            acl.py,  retriever.py,  generator.py,  pipeline.py
        evaluation/run_eval.py,  evaluation/metrics.py
        fixtures/users.json,  fixtures/versions.yaml
        tests/test_loader.py,  test_acl.py,  test_retriever.py
        chroma_db/                          #  生成物（Git管理対象外）
        logs/,  results/                    #  生成物（Git管理対象外）
```

7.2 設定初期値（要約）

キー	値
paths.data_dir	../data（実際にはプロジェクトルート基準で絶対化）
embedding.model	intfloat/multilingual-e5-small
vector_db	chroma / internal_documents_v1 / cosine
chunking	size=500 / overlap=100
retrieval	top_k=5 / acl_enabled=true
llm	ollama / qwen2.5:7b-instruct / temperature=0
evaluation	初期8問 + 拡張30〜50問

7.3 CLI契約

```
python  poc/main.py  ingest  [--rebuild]
python  poc/main.py  ask  --user  user_it_01  [--date  YYYY-MM-DD]
python  poc/main.py  evaluate  [--dataset  PATH]
```

ingestは登録件数・失敗一覧、askは回答・参照元・処理時間、evaluateは指標・失敗ID・実験設定・実行日時を出力する。データ参照先とDB参照先は実行ディレクトリに依存しないよう解決する。

8. PoC評価方法・合格判断

8.1 2段階の評価セット

段階	目的	件数
スモークテスト	パイプライン・既存QAとの整合	既存8問
PoC品質評価	検索、回答、版、表、ACL、根拠不足の層化評価	追加30〜50問
本番受入（別工程）	開発用100＋非公開受入用100、AT準拠	200問

既存QAの「営業担当が経営企画年度予算を閲覧できるか？」は、根拠SC-003への閲覧権限を踏まえて「アクセス拒否試験」と「権限を持つ利用者の規程理解試験」を分離する。

8.2 評価指標と判定方針

指標	PoC一次評価	本番要件との関係
Recall@5	90%以上を暫定目標	AT-01 と同等の算出定義
回答正確性	90%以上を暫定目標	AT-02：最終は独立受入評価
引用の妥当性	95%以上を暫定目標	AT-03 に整合
ACL	漏えい0件（テストで確認）	AT-04：本番50件以上の権限試験
版選択	対象ケース全件正解	AT-05：本番20件全正解
回答保留	分類別に成功率を記録	AT-06：本番20件中18件以上
Injection	権限逸脱・機密漏えい0件	AT-07：本番30件の不正指示
速度	p50 / p95・資源を計測	AT-08：20並列 / p95 8秒 / error<1%

Recall@5は正解文書集合に対する上位5検索結果の文書ID再現率（チャンク重複を集約）で算出。回答品質は正誤と根拠を別採点し、検索ミスと生成ミスを分離する。

8.3 性能計測の注意

PoCの単一PCでは取り込み時間、p50/p95検索時間、生成時間、メモリ/GPU使用量を測定し、20並列および可用性の本番保証はしない。各計測はモデル・量子化・CPU/GPU・データ数・ウォームアップ・反復回数を保存する。

9. セキュリティ評価と課題管理

9.1 重点テスト

領域	検証内容
ACLのFail Closed	未登録ユーザー、権限欠損、禁止文書のID指定、グループ変更、インデックス混在。
Prompt Injection	文書中の回答方針変更指示、偽のSystem記述、無関係URL誘導をデータとしてのみ処理。
出典・引用	取得していない文書の引用拒否、禁止文書名の出力防止、回答保留時の不要開示防止。
取込安全性	ファイル名検証、相対パス脱出防止、マクロ・スクリプト非実行、破損ファイル隔離。
ログ・機密	例外時の本文漏えい防止、出力ログの最小化、テスト結果の閲覧範囲。

PoCテストで成功0件でも絶対安全とは言えない。攻撃条件、観測された挙動、修正案、回帰テストIDを記録する。

9.2 リスク登録票の例

ID	リスク	検証方法	本実装での方向性
R-01	Excel表構造の欠落	価格/予算系QA	抽出仕様・構造化検索を再検討
R-02	Dense検索の取りこぼし	Recall@5分類別集計	Hybrid / Reranker比較
R-03	旧版・現行の混同	基準日時テスト	版管理スキーマの整備
R-04	ACLの条件漏れ	否定ケース・欠損テスト	認可を一元化・自動回帰試験
R-05	ローカル生成の遅延	p50/p95・GPU計測	モデル/推論基盤を再選定

10. 開発工程・完了判定

順序	作業	完了条件
1	環境構築・依存固定	ローカルLLM、E5モデル、DBの単体動作
2	入力照合・文書登録	100件の存在・抽出状況と索引差分を一覧化
3	RAGベースライン	根拠付きの日本語回答が実行可能
4	ACL・日時制御	検索前フィルタ・旧版照会・Fail Closedを確認
5	評価と報告	精度・安全性・性能、未解決課題、技術差分を記録

11. 最終成果物と本番移行判断

成果物	内容
PoC実行コード	poc配下のCLIと主要モジュール、環境構築手順
インデックスと投入レポート	文書取込結果、失敗リスト、モデル・前処理設定
QA・自動テスト	初期8問、拡張QA、pytest、ACLケース、Injectionケース
評価結果	Recall@5、正答率、引用、版、拒否、p50/p95、資源使用量
課題台帳	症状、再現手順、影響、原因候補、対応方針、残余リスク
PoC結果報告書	本番の設計推奨、未検証事項、Go/Conditional Go/No-Go判定

11.1 本番移行ゲート（提案）

・Go：基本性能の一次評価を満たし、重大な情報漏えい・権限逸脱が未解決でない。

・Conditional Go：品質や速度に未達があるが、原因・追加検証・対策方針が明確。基本設計では条件付きで継続。

・No-Go：許可外文書露出、データ破損、再現性がない重大欠陥等が未解決。

11.2 本番設計に持ち越す検討事項

RidgeIDの実認証、20同時利用と1,000質問/日の負荷、Hybrid Search・再ランキング、再インデックス承認、更新反映60分、監査ログ365日、TLS/保存暗号化、RTO/RPO、運用監視、UI/フィードバック、費用上限（月18万円：架空）の評価を別工程で実施する。

> **結論**
>
> 本設計は「無料で動くRAGの制作」だけでなく、何が成立し、どこが不十分で、本番に何を持ち越すかを証拠に基づいて判断するPoCを目的とする。

参考資料：RAG_Dev_Simulation.zip / docs/要件定義書.pdf（v1.0） / docs/企業情報概要.md / data/metadata.jsonl / data/評価用QA_初期セット.jsonl。ZIP内ファイル名表記は原本と正規化後で差異があり得る。